

这次要解决的不是“谁的相关性最强”

找到一个高分描述符不难。

难的是确认它反映的是材料结构，
而不是材料体系、数据记录方式或

CIF

CIF：晶体结构文件，记录原子种类与坐标的标准格式

本次汇报关注三个材料问题

- ① 在 NASICON、硫化物和卤化物里，找到与室温 Na 离子电导率稳定相关的结构量
- ② 去掉“材料属于哪一类”的影响后，相关性是否还在
- ③ 描述符的名字、公式和实际算出的数是否一致

第一轮做了什么，跑完以后发现了什么问题

第一轮流程（跑通可批量比较的筛选框架）



SoftBV：用键价模型估算离子迁移路径； Zeo++：用几何方法找离子通道

跑完以后暴露的五个问题

问题	具体表现	
一	全样本混在一起比	只要能区分 NASICON / 卤化物，全样本就自动跟电导率“强相关”
二	候选和评价同批数据	35 候选 + 七千多符号组合全在同一样本上挑和打分，没有独立验证
三	空位只靠 CIF 占位	只记被精修或建模写出来的位点，没写的不算，混合价无序也看不清
四	外推描述符是否可靠	通过 LOFO， LOAO 的手段计算描述符在不同体系，不同阴离子场景下的相关性，种类太少有过拟合风险
五	描述符依靠精确 CIF 构建	很难从材料设计上给出可靠指导

这五个问题只靠扩充数据集解决不了，需要添加新的筛选规则

第一轮做了什么、发现问题 → 第二轮怎么逐条解决

解决办法

第一轮的问题	第二代怎么解决	现在能做到哪一步
一 全样本混在一起比	先扣掉每一类体系的平均水平，只比同类材料内部谁高谁低	能做到分辨出这是 NASICON 导致拿到高分的
二 候选和评价同批数据	新数据表把总 / 体相 / 晶界 / 方法 / 温度 / 形态 / 相对密度分开记	表已设计、室温挑选规则冻结 体系分类枚举值待人工填定
三 无物理意义组合描述符	未找到低成本准确的解决方案	把描述符按材料意义分组 只允许有物理意义的组合
四 外推描述符是否可靠	第一代只对 8 个候选做了单变量 每个体系内打乱标签算统计显著性	打乱样本重组，组内少于 5 个样本的 不报这个体系的结果
五 描述符依靠精确 CIF	添加新的描述符	第一层有旧数据未接后端 第二层缺可执行文件、三四层要算力

第二代怎样组合描述符

两个描述符搭在一起看，第一代和第二代的搭法完全不同。

对比维度	第一轮	第二代
怎么搭	列出七千多个公式 加减乘除任意组合，按分数挑	先按材料意义分组挑代表 只允许有物理意义的组合
举个例子	“畸变 × 最长键长 ÷ 目标键长” 能算，但材料上说不清为什么这么乘	局域配位配网络配骨架 每类挑一个，看加减乘除是否说得通
量纲	不管，只看分数	长度加长度可以 长度加无关参数不行
结果	容易拼出“高分但材料上解释不通”的公式	组合空间小很多 每个组合都有材料解释

