

从材料体系标签中分离可迁移的钠离子传输结构信号

一个去混杂、稳定性校准和跨体系验证的可解释发现框架

作者信息待补充^{1,*}

¹ 单位信息待补充；* 通信作者信息待补充

摘要 跨 NASICON、硫化物和卤化物汇总离子电导率数据，可以扩大候选结构空间，却也使“结构规律发现”退化为“材料体系识别”：例如较长的 Na-X 距离可能同时标记硫化物化学环境和较高电导率，而未必在各体系内部具有一致作用。本文提出一套面向小样本异质固态电解质数据的可解释发现框架，其目标不是获得最高预测分数，而是判断一个局域结构描述符是否在去除体系背景、扰动样本和留出完整材料体系后仍保留可解释方向。框架将晶体结构描述符记为 X 、材料体系及阴离子背景记为 Z 、室温离子电导率的对数记为 Y ，并使每个算法只解决一种明确的假发现来源：秩感知控制先识别 Z 中的重复化学标签；Ridge 残差化从 X 与 Y 中移除可由 Z 解释的体系均值差异；Spearman 检查剩余结构偏离与电导率偏离是否保持单调关系；子采样 Lasso 和固定噪声列判断该关系是否依赖少数材料；物理族与量纲规则限制二元和三元组合，避免无界符号搜索；阴离子分层、留一体系和重复子采样分别检验体系内插值、未见体系迁移和划分敏感性；V1-V4 进一步审计随机公式、已知因素后的折外预测、体系内方向和重采样不确定性。Pipeline 与单描述符 Agent 只共享冻结输入，在授权比较前隔离结果。当前分支引用的 84 个 CIF 尚不可用，因此本文报告算法设计、软件契约和合成测试，而不宣称已经识别出新的最佳描述符或离子迁移机制。

引言：本工作不是预测竞赛，而是结构规律发现

固态电解质中的 Na^+ 迁移不是由单一几何量控制。局域 Na-X 配位决定离子离开原位点需要克服的束缚，Na 位点和空位数量决定可用载流子与落脚点，Na-Na 网络和间隙拓扑决定这些位点能否连接成长程通道，骨架柔性则可能调节迁移瓶颈随热运动开启的程度。因此，从 CIF 中计算局域结构描述符并与离子电导率关联，是建立结构设计规则的一条自然路径 [1, 2]。

但是，跨体系汇总数据后，“预测电导率”和“发现可迁移结构规律”不再是同一个问题。NASICON、硫化物和卤化物在阴离子尺寸、极化率、键合类型、骨架单元和典型电导率范围上均存在系统差异。一个模型只要识别出材料属于哪一类，就可能获得不错的预测分数。例如，若硫化物在当前数据中通常具有较长 Na-S 距离和较高电导率，而氧化物具有较短 Na-O 距离和较低电导率，那么全数据会呈现“Na-X 距离越长，电导率越高”。这一相关可能完全来自硫化物与氧化物之间的均值差，而不是同一体系内部改变 Na-X 距离就能提高电导率。

因此，本工作的核心问题不是

“哪个描述符最能预测 Y ？”

而是

“哪个局域结构描述符 X 在去除材料体系与阴离子背景 Z 后，仍与离子电导

20

率 Y 保持稳定、方向明确并可跨体系复核的关系?”

这里 X 是从 CIF 计算的 Na 配位、Na–Na 网络、Na 浓度、空位拓扑、骨架和对称性等结构量; Z 是 NASICON、sulfide、halide 及有效阴离子对比; $Y = \log_{10}(\sigma/\text{S cm}^{-1})$ 。图 1 将这一任务拆成五个相互独立的困难。Pipeline 的每一步都不是为了堆叠模型复杂度, 而是为了排除一种特定的错误结论。




图 1. 从异质固态电解质数据库中发现结构规律面临的五类障碍。描述符 X 、体系背景 Z 与电导率 Y 之间同时存在化学分群、描述符冗余、小样本扰动、公式搜索自由度和验证域偏移。框架的目标是逐层排除这些假发现来源, 而不是用更复杂的模型掩盖它们。

文章的结论单位。本框架最终输出的不是“预测器”, 而是进入下一轮物理验证的候选结构假设。一个候选只有在数据可审计、去混杂关联保留、稳定性超过噪声、公式物理合法、跨体系方向可复核且不确定性可见时, 才有资格进入 BVSE、NEB、AIMD 或实验验证。

为什么常规材料机器学习不能直接回答这个问题

晶体图神经网络能够从原子连接中学习高维表示, 并在拥有约 10^4 或更多训练样本时展现强预测能力 [3, 4]。随机森林和梯度提升树也擅长拟合复杂非线性关系。然而, 这些方法的主要目标是最小化测试误差。当体系类别本身携带大量目标信息时, 模型可以通过学习“硫化物通常更导电”获得较高精度, 却不需要学习“同一体系内哪些局域结构改变与电导率共同变化”。即使使用特征重要性, 也难以区分一个变量是在描述迁移机制, 还是只在识别材料类别。

此外, 当前样本规模约为 84 行, 远小于深度结构模型通常发挥优势的数据量。Matbench 的基准结果表明, 晶体图方法的优势主要在较大数据任务中显现, 而数百样本级任务中,

35 经过合理验证的传统描述符模型仍具有竞争力 [4]。近期材料机器学习研究也显示，许多所谓分布外测试实际上仍处在训练表示空间覆盖范围内，容易高估对未知化学或结构域的泛化 [5]。因此，本研究主动限制模型容量，把计算资源用于混杂审计、稳定性和域外验证，而不是追求一个难以解释的非线性预测器。

40 通用符号回归和 SISSO 可以从大量初始特征中生成低维解析公式，并已用于材料描述符发现 [6]。它们与本研究追求可解释公式的方向一致，但当前数据存在两个额外问题：第一，体系标签与结构描述符强耦合，若不去混杂，符号搜索会优先放大体系差异；第二，84 个样本不足以支持包含大量对数、幂、根式和任意比值的巨大公式空间。因此，本框架没有直接采用无界 SISSO 或遗传式符号回归，而是先压缩为稳定的物理族代表，再只执行声明式、量纲可审计的二元和受限三元组合。

表 1. Pipeline 中各算法解决的科学问题、来源与选择理由。每个模块都围绕描述符 X 、体系背景 Z 和电导率 Y 的关系设计。

模块	要排除的错误	主要来源领域	在本工作中的选择逻辑
物理描述符	黑箱表示无法转化为 Na^+ 迁移假设	晶体化学、图论、Voronoi 几何、材料信息学	把 CIF 分解为局域束缚、载流子条件、网络连通、空位和骨架响应；结果可以返回结构与材料设计。
秩感知控制	system 与 anion 重复编码同一化学分群	线性模型、实验设计、秩诊断	先判断阴离子标签是否在体系标签之外增加信息，避免把冗余 dummy 当成独立控制。
Ridge 残差化	X - Y 相关由体系均值差伪造	正则化回归、流行病学协变量调整、计量经济学 partialling-out	在共线小样本中稳定估计“该体系通常具有怎样的描述符和电导率”，再比较体系内偏离。
Spearman	结构-电导率关系可能单调但非线性	非参数统计	关注排序方向，不要求描述符变化与 $\log \sigma$ 呈严格直线；比 Pearson 更符合探索性结构规律。
子采样 Lasso	单次筛选由少数材料或相关变量竞争决定	高维统计、基因与生物标志物筛选	Lasso 产生明确非零选择事件；重复半样本后，以选择频率判断一个描述符是否反复出现。
固定噪声校准	多变量搜索中随机特征也会偶然高分	负对照、经验零分布、置换思想	让无意义变量参加同一筛选，真实描述符必须超过噪声选择频率的高分位数。
物理规则组合	任意代数组合造成组合爆炸与伪公式	量纲分析、物理约束符号回归	只允许预先审查的族邻接、方向比值和量纲相容运算；牺牲搜索空间换取可审计性。
折内 Ridge CV	全局插补/缩放泄漏测试材料信息	预测模型验证	每个训练折独立估计中位数、尺度和回归系数；Ridge 此处只作为低容量探针，检验候选是否含可复现排序信息。
LOSO 与多策略 CV	随机划分把同体系近邻放入训练与测试	分组验证、domain generalization	留出完整材料体系模拟“未知化学域”；其它策略分别检验插值能力和划分敏感性。
V1-V4	单一相关系数无法排除公式自由度、单体系驱动和高方差	置换检验、正交化预测、分层分析、bootstrap	为同一公式提供四类互补证据，并对不可用证据显式标记。

45 框架总览：每一步只回答一个问题

图 2 给出从结构到候选假设的完整逻辑。Stage 0 不做统计推断，只确保 X 真正来自可解析结构；Stage 1 询问 X 与 Y 的关系在移除 Z 后是否保留；Stage 2 询问这一关系在样本扰动下是否反复出现；Stage 3 询问多个物理环节能否通过简单、量纲合理的公式表达协同；Stage 4 询问该候选在不同体系划分下是否还能排序电导率。V1-V4 和 Agent 轨道提供额外审计，但均不能把关联提升为因果结论。




图 2. 各模型在描述符筛选中的实际作用。Ridge 在 Stage 1 中估计体系背景，在 Stage 4 中作为低容量折外探针；Spearman 衡量结构偏离与电导率偏离的单调方向；Lasso 只负责产生稳定选择事件；规则组合和分组验证分别控制公式自由度与材料体系外推。

Stage 0: 结构描述符不是普通特征，而是迁移机制假设

框架保留 41 个公开描述符 callable，其中 38 个为当前活动搜索项。它们被分为八个物理族。A 族描述 Na 配位多面体，例如 Na-X 键长、配位数、多面体体积和畸变；这些量对应 Na⁺ 离开局域势阱时的束缚环境。B 族描述 Na-Na 网络，包括邻居数、最大连通分量和网络维度，用于判断局域位点能否连接成长程迁移网络。C 族描述 Na 浓度、占位和位点

数，近似表征载流子与可用位点条件。D' 族从周期性 Voronoi 顶点构造间隙候选，描述空位可达性与间隙网络。E 和 F 族分别描述骨架刚性、多面体共享和长程路径几何。G 和 H 族包含电负性、形式电荷、空间群和 Wyckoff 多样性等代理量，它们可能有效，但更容易成为材料体系标签，因此被预先标记为高风险。

这种表示与图神经网络的差别在于，每个输入列都有明确的问题指向。例如，若 d_{network} 增大并与 Y 同向变化，可以提出“更高维 Na 位点连通性可能支持长程迁移”的假设；若空间群编号获得高分，则首先应怀疑它在识别材料家族，而不是直接解释离子迁移。描述符族不是统计分组便利，而是后续避免重复发现和约束公式的物理先验。

软件层面的失败关闭同样属于科学设计。带电 Pymatgen Species 必须按元素身份识别，部分占位按元素累计；相对 CIF 路径固定相对于原始 CSV 解析；全部 CIF 在写结果前检查存在性和可解析性；别名、未实现描述符和全缺失特征不能进入搜索。若 Stage 0 没有足够结构信息，正确结果是停止，而不是让插补器生成一张形式完整的排名表。

Stage 1: Ridge 去除体系背景，Spearman 检查体系内结构趋势

一个直观的混杂例子

图 3 是概念示意而非真实结果。设 X 为平均 Na-X 距离，Z 为材料体系，Y 为 $\log \sigma$ 。若硫化物整体位于“较长键、较高电导率”区域，NASICON 位于“较短键、较低电导率”区域，全样本会出现明显正相关。但在每个体系内部，点云斜率可能接近零。此时模型若直接使用 X 预测 Y，实际上是在利用 X 猜测 Z。




图 3. 体系均值差如何伪造结构-电导率关系。 a, 全样本中 Na-X 距离与 $\log \sigma$ 呈正相关；颜色揭示该趋势主要来自三类体系中心不同。b, Ridge 分别估计体系对描述符和电导率的期望。c, 减去体系期望后，比较“相对同类材料结构更开放”是否对应“相对同类材料更导电”。图为方法示意，不代表当前 84 样本结果。

为什么先做秩感知控制

当前数据设计中, 30 个 NASICON 样本全部标为 oxide, 41 个 sulfide 样本全部标为 sulfide, 13 个 halide 中有 12 个 chloride 和 1 个 iodide。若 system 与 anion 全部 one-hot 编码, oxide 和 sulfide 列可以由 system 列完全重构。将这些列机械地放入同一个回归, 并不会增加化学信息, 反而使参数依赖编码方式。

因此, 框架先放入 system, 再逐列检查 anion 对比是否增加带截距设计矩阵的秩。当前只有 halide 内的 iodide-chloride 对比增加一个秩。该步骤来自线性模型的设计矩阵诊断, 其作用不是“提高预测”, 而是明确 Z 中哪些化学标签真正提供独立背景信息。

Ridge 在这里估计的不是结构效应, 而是体系期望

对每个描述符 X_j , 框架分别拟合

$$\hat{X}_j = f_{\text{Ridge}}(Z), \quad (1)$$

$$\hat{Y} = g_{\text{Ridge}}(Z). \quad (2)$$

这里 $\hat{X}_j$ 可理解为“只知道材料属于哪一体系时, 预计它具有怎样的描述符”; $\hat{Y}$ 是“只知道体系背景时, 预计它具有怎样的电导率”。残差

$$X_j^{\text{res}} = X_j - \hat{X}_j, \quad (3)$$

$$Y^{\text{res}} = Y - \hat{Y} \quad (4)$$

分别表示材料相对于同类材料的结构偏离和电导率偏离。最终问题变成：一个材料若比同体系平均水平具有更高的配位畸变、更连续的 Na 网络或更多可达间隙, 它是否也比同体系平均水平更导电?

Ridge 最初用于非正交预测变量下的稳定回归 [7]。本数据中的 system 和 anion 正是高度共线的分类变量。普通最小二乘可能产生高方差系数; Lasso 可能在相关控制列之间任意选择并删除某些背景; 随机森林虽然能拟合更复杂的 $Z \rightarrow X$ 和 $Z \rightarrow Y$ 关系, 但残差来源更难审计, 且 84 行数据不足以支持高容量背景模型。因此选择 Ridge 作为保守的体系均值校正器。

为什么在残差上使用 Spearman

框架计算

$$\rho_{\text{deconf},j} = \rho_s(X_j^{\text{res}}, Y^{\text{res}}). \quad (5)$$

Spearman 相关源于等级关联统计 [8]。它不要求描述符每增加一个固定单位, $\log \sigma$ 就线性改变; 只要求结构偏离的排序与电导率偏离的排序具有一致方向。这适合离子传输问

题，因为静态几何与电导率之间可能包含阈值、饱和和未观测温度动力学。Pearson 对直线关系更敏感；互信息可以发现更一般的非线性，却在小样本中估计不稳且不提供明确正负方向。对需要形成“增加或降低某结构量可能有利”的候选规则，Spearman 更合适。

该残差相关仍不是因果效应。它只移除了已观测的体系与有效阴离子背景，无法排除密度、烧结工艺、相纯度、测量频率、晶界和未记录缺陷等混杂。框架因此使用“去混杂关联”而非“结构效应”或“机制证明”[9, 10]。

Stage 2: Lasso 稳定性选择回答“这个描述符是否依赖少数材料”

单次筛选在小样本材料数据中非常脆弱。两个 A 族描述符可能都在表达 Na 配位尺度，删除几个样本后 Lasso 可能从平均键长切换到多面体体积；一个空间群代理也可能因某次划分恰好获得高系数。单次“入选”不足以支持结构假设。

Lasso 通过 L_1 惩罚把部分系数压为严格零，因此天然给出“这次子样本中是否选择该描述符”的事件[11]。框架重复 100 次无放回半样本抽取，在每个子样本内部单独执行中位数插补、标准化和 Lasso($\alpha = 0.05$)。稳定性分数是非零系数出现的比例。该思想来自高维统计中的 stability selection，已广泛用于变量和生物标志物筛选[12]。

这里 Ridge 与 Lasso 的职责必须区分：Ridge 在 Stage 1 中平滑估计体系背景，在 Stage 4 中作为低容量预测探针；Lasso 只在 Stage 2 中制造稀疏选择事件。若用 Ridge 做稳定性选择，几乎所有特征都会得到非零系数，无法定义清晰的入选频率。若只运行一次 Lasso，则相关描述符之间的竞争会使结果依赖一次抽样。

固定加入 15 个标准正态噪声列，回答另一个问题：在 38 个真实描述符和多次搜索中，一个完全无意义的变量最多可以表现多好？真实描述符不仅需要选择频率超过 0.60，还必须超过噪声选择频率的第 95 百分位数。噪声列不是正式假发现率控制，但提供了与当前样本量、候选数和 Lasso 设置一致的经验零基线。

随后按物理族选择代表。这样做不是为了平均分配名额，而是防止平均 Na-X 距离、最大键长和多面体体积把同一局域尺度重复包装成多个“独立发现”。二元模式每族最多一个代表；三元模式每族最多两个，第二个名额仅用于“同族两个互补量 + 相邻族一个量”的受限公式，不被视作第二项独立科学结论。

Stage 3: 受约束组合搜索表达多因素迁移，而不制造任意公式

Na^+ 传输通常需要多个条件同时满足。较弱的局域束缚若没有连续 Na 位点网络，可能仍无法形成长程扩散；大量空位若对应高度弯曲或低维通道，也未必提高宏观电导率。因此，组合描述符具有物理必要性。但从 38 个特征任意生成加、减、乘、除、对数和幂函数，会使搜索空间急剧膨胀，小样本中几乎必然出现高相关公式。

本框架借鉴材料符号描述符发现与量纲约束思想[6]，但把搜索空间压缩为人工审查过的规则表：同族允许加法或乘法；跨族只允许 A-B、A-D'、B-D'、A-E、A-H 等明确邻接；自动比值只允许 A/C 方向；加法要求已知维度一致；零或非有限分母保留为缺失；禁止 log、sqrt 和 power。三元式只能由同族两个代表先结合，再与一个显式相邻族代表结合。

这种规则的含义可以用实际对象解释。例如，A/C 比值可把“局域配位几何尺度”与“Na 位点数量条件”联系起来，但反向 C/A 不会因统计得分自动生成； $A \times B$ 可以表示局域环境与网络连通的协同； $A + E$ 只有在维度相容时才允许。每个公式保存组分、物理族、运算符、规则编号、原始值来源、缺失策略和标准化时机。搜索器无法隐藏一个公式是怎样产生的。

与 SISSO 或通用符号回归相比，这一做法可能遗漏真实但未被规则允许的关系。该

损失是有意的：当前目标是获得少量可人工审查、可在结构中定位并可交给 AIMD/实验验证的假设，而不是证明所选公式是所有数学表达式中的全局最优。

Stage 4: 交叉验证不是一个分数，而是三个不同的科学问题

候选公式进入预测验证后，Ridge 的角色再次改变。此时不再用于去除体系背景，而是作为低容量探针：若一个或两个描述符确实携带稳定的电导率排序信息，一个简单的线性正则模型应能在未见样本上恢复部分排序；若只有高容量非线性模型才能取得性能，则很难判断信号来自结构规律还是模型自由度。

每个训练折独立拟合中位数插补、标准化和 Ridge。测试材料的描述符分布不能提前参与中位数或尺度估计。将预处理放在全数据上再交叉验证，会使测试折信息泄漏到训练过程；在模型选择后使用同一 CV 分数作为无偏性能估计也会产生乐观偏差 [13]。

三种验证分别回答不同问题：

1. **阴离子分层 CV**：在训练和测试具有近似化学组成比例时，候选能否对未见材料进行体系内插值？它主要检验常规预测稳定性。当前 iodide 仅一例，因此该策略必须跳过，不能生成一个看似完整的三折平均。
2. **留一体系验证 (LOSO)**：若 NASICON、sulfide 或 halide 整个体系从未进入训练，候选在该未知化学域中是否仍保持电导率排序？这是最接近本研究“跨体系可迁移”目标的测试。
3. **重复体系分层子采样**：在 10 次 80/20 划分中，候选表现是否依赖某一次幸运划分？它估计的是划分敏感性，而不是体系外推。

综合分只平均实际可用策略的绝对 Spearman，并同时报告可用策略数。策略跳过表示“没有证据”，不是负证据，更不能被填成零分。一个候选即使在随机子采样中表现良好，若 LOSO 方向反转，也不能称为跨体系结构规律。

V1-V4: 从一个相关系数扩展为多层证据

Stage 4 的 Top 候选进一步接受四类互补审计。

1. **V1 匹配公式噪声**：在每个材料体系内部打乱公式各分量，再使用完全相同的运算符重建公式。它回答“该复杂公式是否只是因自由度增加而偶然高相关”。
2. **V2 已知因素后的折外残差预测**：训练折先根据 Z 估计目标的体系背景，再让候选公式预测未见样本的 Y 残差。它回答“在已知体系因素之外，公式是否仍含可折外复现的信息”。这是一种正交化预测关联，不是因果效应。
3. **V3 体系内方向**：分别在 NASICON、sulfide 和 halide 内计算公式与 Y 的 Spearman。它回答“全局关系是否完全由一个体系驱动”。
4. **V4 体系分层 bootstrap**：在每个体系内部有放回抽样，保持体系构成并估计相关区间。它回答“固定公式的关联对材料重采样有多敏感”。

V1-V4 不可互相替代。一个公式可能超过置换噪声，却只在 sulfide 内成立；也可能各体系方向一致，但 bootstrap 区间很宽；还可能在固定公式条件下表现稳定，却因缺少外层“重新筛选-重新组合”的 nested reselection 而低估选择不确定性。文章必须同时呈现证据与缺口。

Pipeline 与 Agent 双轨：防止发现过程验证自己

Pipeline 批量筛选单描述符并构造二/三元公式；Agent 每次只评估一个研究者明确指定的活动描述符。两条轨道共享冻结的 raw CSV、描述符注册表及修订号，但分别写入 results/pipeline/ 与 results/agent/，在用户授权 C9 前不能读取对方结果。

这种隔离借鉴独立复核与三角验证思想。若 Pipeline 的组合搜索和 Agent 的单变量审计都指向 Na 网络连通性，说明该方向值得优先检查，但不能把一致性解释为因果证明。




图 4. 一个描述符从相关变量升级为物理验证候选所需的证据阶梯。任一步失败都指出一种不同的风险：体系代理、样本不稳定、随机公式、单体系驱动或跨域失效。通过全部层级仍只意味着“值得进一步验证”，并不直接证明迁移机制。

若两轨不一致，也不是简单失败：它可能揭示组合公式依赖特定协同、单变量信号不稳，或 Pipeline 的搜索空间与 Agent 的人工假设不一致。

一个候选何时才算“可解释的局域结构信号”

本框架将候选资格定义为一条可审计链，而不是单一阈值：

1. 结构文件存在、可解析，描述符有明确单位、物理族和计算 provenance；
2. 描述符与 Y 的关系不是仅由 system/anion 均值差驱动；
3. 在半样本 Lasso 中反复入选，并超过固定噪声基线；
4. 若形成组合，运算来自预先声明的物理规则且量纲可解释；
5. 在至少一种常规验证和 LOSO 中具有可用证据，方向冲突被显式报告；
6. V1-V4 不显示明显随机公式、单体系驱动或极端重采样不确定性；
7. 候选能够返回具体结构对象，例如 Na 配位、位点网络或间隙通道，并可提出可验证的材料学预测。

只有完成这些步骤，候选才进入后续 BVSE/BVEL、NEB、AIMD 或实验验证。静态 CIF 描述符无法直接给出有限温度迁移势垒，也不能代表晶界、相变和制样工艺。因此，Pipeline 的最终产物是“优先验证列表”，不是材料机制终局。

当前实现状态与本文能够支持的结论

修复分支通过 70 项自动化测试、Python 全量编译和 CLI 冒烟检查。测试覆盖带电物种、混合占位、周期最小像、Wyckoff 多样性、全缺失失败关闭、折内插补、不可行 CV 的 skip 语义、Stage 1-2 合约、硬物理族容量、真实三元式生成、严格 JSON 往返、V1-V4 provenance、双轨隔离和冻结身份检查。

但当前 checkout 中 raw CSV 引用的 84 个 CIF 不可用。Pipeline 与 Agent 因而会在任何研究结果写入前失败。这一状态证明了失败关闭设计能够阻止全 NaN 特征被误写为材料学发现，却不能证明哪个真实描述符与电导率相关。因此，本稿不报告“最佳单描述

符”“最佳组合”“组合提升百分比”或新的迁移机制。补齐并冻结 CIF 后，必须从 Stage 0 重新运行，并将真实数据图替换本文中的概念示意图。

讨论：该框架的优势、代价与适用边界

该框架的首要优势是把每个模型的职责限制在一个可解释问题内。Ridge 不是被笼统称为“机器学习模型”，而是先用于估计体系背景，后用于折外探测简单候选；Lasso 不用于解释系数大小，而只用于生成可重复的选择事件；Spearman 不承担复杂非线性拟合，而用于保留结构趋势方向；LOSO 不追求平均分最高，而是主动制造最困难的未知体系测试。这种职责分离减少了算法之间的语义混乱。

代价是框架较为保守。秩感知残差化可能移除一部分真实但与体系高度绑定的机制；稳定性选择可能在一组高度相关的同类描述符之间分散频率；受限公式搜索可能遗漏未写入规则表的真实表达；LOSO 在只有三个体系时方差很大。保守并不等于这些方法绝对优于 RF、XGBoost、GNN 或 SISSO，而是它们与当前目标和数据规模更匹配。未来样本扩展到数千并具有独立外部体系后，可以将图网络作为预测基线，或在已经完成去混杂与稳定压缩的候选空间上运行更广泛的符号回归。

最后，关联稳定性不等于机制稳定性。即使一个 Na 网络描述符通过所有统计门槛，也可能只是未记录缺陷浓度或相纯度的代理。真正的机制证据需要在结构扰动、组成系列、温度依赖电导、迁移势垒和有限温度轨迹中得到一致支持。本文框架的价值，是把海量结构变量压缩成少量、证据链透明且可以被计算和实验反驳的候选假设。

方法

软件范围与冻结配置

本文对应仓库 northkd/pull_file 的 codex/naconductor-repair 分支。Pymatgen 用于 CIF 解析和结构操作，NumPy、SciPy、pandas 与 scikit-learn 用于数值、统计和模型流程 [14–16]。运行配置由 run_info.yaml 提供：目标列为 log_sigma，结构列为 cif_path，体系列为 system，阴离子列为 anion_type；Ridge 正则化系数为 1.0；稳定性 Lasso 系数为 0.05；100 次 50% 无放回子采样；选择频率阈值为 0.60；15 个固定标准正态噪声列；组合公式含 2–3 个描述符；重复子采样执行 10 次，测试比例 0.2，随机种子 42。

冻结身份包含原始 CSV 的规范路径、实际载入的描述符注册表路径和注册表修订号。配置中的 raw 文件与 shared input 必须解析为同一文件，注册表配置必须指向当前 Python 导入模块。Pipeline 和 Agent 工件均保存该身份；混合批次或外来注册表被拒绝。

CIF 预检与描述符注册

相对 CIF 路径始终相对于原始 CSV 目录解析。Pipeline 在初始化描述符列及写 CSV/JSON 前检查全部路径；Agent 进一步逐一调用 Pymatgen 解析结构。任一缺失或不可解析结构均中止整批运行。单个描述符失败可以记录 NaN，但若一个描述符少于 5 个有限值，或 Stage 0 没有达到覆盖阈值的活动描述符，则停止分析。

注册表保留 41 个公开 callable；max_bond_length 是 a2_max_dist 的兼容别名，bottleneck_anisotropy 和 bvse_barrier_estimate 当前无有效实现，三者不进入自动搜索，其余 38 项为活动描述符。每项记录单位、物理维度、物理族、高风险状态、活动状态和别名关系。

化学物种、占位与周期几何

元素身份通过规范元素符号识别，而不是比较带电物种显示字符串。Na、阴离子、框架元素和部分占位均按元素占位求和。D' 族间隙候选来自实际周期 Voronoi 顶点；距离使用晶格最小像并按周期最小像去重。Wyckoff 多样性通过 Pymatgen 的对称化结构接口获

得，并定义为 `equivalent_indices` 的等价位点组数。

特征覆盖与固定噪声

活动描述符至少需要在 50% 样本中有限。原始值和 NaN 原样保留，不进行全局插补或标准化。以种子 42 生成 15 列 $\mathcal{N}(0, 1)$ 噪声，仅用于稳定性经验基线，不进入物理代表和公式搜索。

秩感知控制与 Ridge 残差化

`system` 与 `anion` 均采用参考类别虚拟编码。先构造带截距的 `system` 设计矩阵，再按固定列顺序尝试加入 `anion` 对比；只有增加矩阵秩的列进入实际控制矩阵。输出保存 `system` 秩、完整控制秩、阴离子增量秩、冗余列、增量列和最终残差化列。

对每个至少有 5 个有限 X_j - Y 配对的描述符，以 $\text{Ridge}(\alpha = 1)$ 分别拟合 $X_j \sim Z$ 和 $Y \sim Z$ ，计算残差 Spearman。原始相关接近零时体系代理比设为 0；原始和去混杂相关符号相反时设为 1；否则计算并截断 $1 - \rho_{\text{deconf}}^2 / \rho_{\text{raw}}^2$ 到 $[0, 1]$ 。 $|\rho_{\text{raw}}| < 0.2$ 标记噪声级；否则 $|\rho_{\text{deconf}}| > 0.3$ 标记强物理信号；其余按代理比阈值标记弱物理、混合或体系代理。这些标签用于候选压缩，不作为显著性检验。

子采样 Lasso 与物理族代表

Stage 2 只接受 Stage 1 标记为强物理、弱物理或混合信号的活动描述符，并加入全部固定噪声。每次无放回抽取一半样本，新建 `SimpleImputer(strategy=median) - StandardScaler - Lasso(alpha=0.05, max_iter=20000)` 管线。系数绝对值大于 10^{-12} 计为选择。100 次后，真实描述符需同时满足频率 > 0.60 和超过噪声频率第 95 百分位数。

在稳定且超过噪声基线的描述符中，按 $|\rho_{\text{deconf}}|$ 选择物理族代表。二元模式每族最多一个，三元模式每族最多两个；该容量为硬上限。

受约束公式搜索

公式在原始物理值上按左结合顺序计算。加法和乘法使用无序组合避免交换律重复；比例只根据有向规则生成。分母必须有限且非零。加法要求两个已知维度一致；未知外部描述符可保留以兼容自定义注册表。禁止 `log`、`sqrt` 和 `power`。

二元候选来自同族或声明式跨族规则。三元候选固定为同族两个代表先以加法或乘法结合，再与显式相邻族一个代表结合。候选至少有 5 个有限公式-目标配对，按去混杂 Spearman 绝对值排序并最多保留 150 个。组分、运算符、物理族、规则、原始值来源、缺失策略和标准化时机使用严格 JSON 写入 CSV；读取时校验 2-3 个组分、 $n - 1$ 个运算符、兼容字段和 `provenance` 一致性。

折内模型与三种交叉验证

每个训练折独立拟合中位数插补、标准化和 $\text{Ridge}(\alpha = 1)$ 。阴离子分层使用打乱的 `StratifiedKFold`，请求 3 折；最小类别少于 2 时跳过，支持 2 折时显式降折。LOSO 使用 `LeaveOneGroupOut`，按 `system` 留出整组。重复子采样使用 `StratifiedShuffleSplit`，精确执行 10 次、测试比例 0.2 和种子 42；若类别支持或训练/测试规模不足则跳过。

单折报告测试 Spearman 和 MAE。策略均值只使用有限折。综合分为所有未跳过且均值有限策略的绝对 Spearman 平均值，并保存可用策略数、是否完整和 `skip` 原因。

V1-V4 探索性证据

V1 在每个 `system` 内独立置换公式分量，保持公式结构并生成 100 个匹配噪声公式，报告噪声绝对 Spearman 中位数、第 95 百分位数和观测百分位。V2 在训练折内用秩感知控制拟合目标并形成训练和测试残差，再以折内插补-标准化-Ridge 让公式预测测试残差，

汇总 OOF Spearman。V3 分别在各 system 内计算原始 Spearman。V4 在各 system 内有放回抽样，默认 500 次，报告 2.5% 和 97.5% 分位区间。V4 不重新执行描述符选择和公式搜索，因而不包含选择不确定性。所有区块返回 status=exploratory、available 和 reason，整体固定 causal_claim=false。

Agent 单描述符审计与双轨隔离

Agent CLI 要求显式 --descriptor-name，且名称必须为活动描述符。它对冻结 CSV 中全部 CIF 做存在性和解析性预检，逐结构计算指定描述符，并使用与 Pipeline 相同的秩感知去混杂和 CV 实现。Agent 结果 TSV 保存覆盖、失败数、原始/去混杂 Spearman、代理比、标签、CV 指标、综合分和冻结身份；审计 CSV 保存材料、CIF、体系、阴离子、目标和描述符原始值。

Pipeline 只写 results/pipeline/，Agent 只写 results/agent/。绝对路径、父目录跳转和跨轨写入均被拒绝。在用户授权 C9 前，两轨不能读取对方结果；C9 只对已完成冻结工件进行只读比较。

测试、真实运行与结果冻结

修复分支记录 pytest -q (70 passed)、python -m compileall -q . 以及五个 CLI 帮助入口检查。额外冒烟验证缺失 CIF 时不创建 Pipeline/Agent 结果；旧全缺失特征表被拒绝；合成数值数据能够顺序执行 Stage 1–4，并产生真实三元候选、严格 JSON provenance、V1–V4 和策略 skip 状态。

补齐真实 CIF 后，应保存结构文件哈希、raw CSV 哈希、注册表修订号、软件环境、随机种子、每阶段 CSV/JSON、每折索引和预测值。任何论文结果必须绑定一个冻结提交和运行目录。

数据与代码可用性

代码、配置、测试和手稿位于 northkd/pull_file 仓库的 codex/naconductor-repair 分支。当前修复提交没有补齐 raw CSV 引用的 84 个 CIF，也没有重新生成真实 Stage 0–4 结果。补齐结构后必须从冻结 raw CSV 重新特征化，不能沿用旧全缺失特征表。

致谢

致谢信息待补充。

作者贡献

作者贡献信息待补充。

利益冲突

作者声明信息待补充。

补充信息

建议补充材料包括：41 个公开描述符的定义、单位和算法；38 个活动描述符清单；公式规则注册表；控制矩阵秩审计；全部测试目录；合成端到端输出；真实数据补齐后的 Stage 0–4 工件、结构哈希和环境锁定文件。当前 PDF 不包含未运行的 BVSE、DFT、NEB 或 AIMD 结果。

参考文献

- 330 [1] Stefan Adams and R. Prasada Rao. “High throughput ionic conductivity screening of NASICON-type structures”. In: *physica status solidi (a)* 203.6 (2006), pp. 1226–1234.
- [2] Austin D. Sendek, Qian Yang, Ekin D. Cubuk, et al. “Holistic computational structure screening of more than 12,000 candidates for solid lithium-ion conductor materials”. In: *Energy & Environmental Science* 10 (2017), pp. 306–320.
- 335 [3] Tian Xie and Jeffrey C. Grossman. “Crystal Graph Convolutional Neural Networks for an Accurate and Interpretable Prediction of Material Properties”. In: *Physical Review Letters* 120.14 (2018), p. 145301.
- [4] Alexander Dunn, Qi Wang, Alex Ganose, et al. “Benchmarking materials property prediction methods: the Matbench test set and Automatminer reference algorithm”. In: *npj Computational Materials* 6 (2020), p. 138.
- [5] Kangming Li, Andre Niyongabo Rubungo, Xiangyun Lei, et al. “Probing out-of-distribution generalization in machine learning for materials”. In: *Communications Materials* 6 (2025), p. 9.
- 340 [6] Runhai Ouyang, Stefano Curtarolo, Emre Ahmetcik, et al. “SISSO: A compressed-sensing method for identifying the best low-dimensional descriptor in an immensity of offered candidates”. In: *Physical Review Materials* 2.8 (2018), p. 083802.
- [7] Arthur E. Hoerl and Robert W. Kennard. “Ridge Regression: Biased Estimation for Nonorthogonal Problems”. In: *Technometrics* 12.1 (1970), pp. 55–67.
- 345 [8] Charles Spearman. “The Proof and Measurement of Association between Two Things”. In: *The American Journal of Psychology* 15.1 (1904), pp. 72–101.
- [9] Judea Pearl. *Causality: Models, Reasoning, and Inference*. 2nd ed. Cambridge: Cambridge University Press, 2009.
- 350 [10] Victor Chernozhukov, Denis Chetverikov, Mert Demirer, et al. “Double/debiased machine learning for treatment and structural parameters”. In: *The Econometrics Journal* 21.1 (2018), pp. C1–C68.
- [11] Robert Tibshirani. “Regression Shrinkage and Selection via the Lasso”. In: *Journal of the Royal Statistical Society: Series B (Methodological)* 58.1 (1996), pp. 267–288.
- [12] Nicolai Meinshausen and Peter Bühlmann. “Stability selection”. In: *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 72.4 (2010), pp. 417–473.
- 355 [13] Sudhir Varma and Richard Simon. “Bias in error estimation when using cross-validation for model selection”. In: *BMC Bioinformatics* 7 (2006), p. 91.
- [14] Shyue Ping Ong, William Davidson Richards, Anubhav Jain, et al. “Python Materials Genomics (pymatgen): A robust, open-source python library for materials analysis”. In: *Computational Materials Science* 68 (2013), pp. 314–319.
- 360 [15] Charles R. Harris, K. Jarrod Millman, Stéfan J. van der Walt, et al. “Array programming with NumPy”. In: *Nature* 585 (2020), pp. 357–362.
- [16] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, et al. “Scikit-learn: Machine Learning in Python”. In: *Journal of Machine Learning Research* 12 (2011), pp. 2825–2830.