

去混杂的局域结构描述符揭示钠离子固态电解质的跨体系传输规律

作者信息待补充^{1,*}

¹ 单位信息待补充; * 通信作者信息待补充

摘要 固态电解质的宏观离子电导率由局域配位、可达空位、迁移网络和骨架响应共同决定，但跨材料体系的统计分

析容易把体系类型误识别为普适结构规律。本文建立一套面向小样本、多体系数据的混杂感知描述符搜索框架：对原始晶体结构进行质量控制，从局域几何中构建八类物理描述符；以体系类型和阴离子类别作为混杂变量实施 Ridge 残差化；通过随机噪声校准的稳定性筛选和物理约束组合搜索压缩候选空间；最后利用阴离子分层交叉验证、留一体系验证和重复子采样评估可迁移性。当前分析表明，未经控制的高相关描述符中包含明显的体系代理信号，而去混杂后保持稳定的候选主要来自 Na 配位多面体、Na-Na 网络和载流子条件。该框架不以追求最高预测精度为首要目标，而强调可解释性、跨体系稳健性和完整复现，为后续第一性原理或分子动力学验证提供可审计的候选排序。

固态电解质是全固态电池中同时承担离子传输和物理隔离功能的关键材料。与液态体系相比，晶态固体中的离子迁移受到局域配位势阱、位点占据、骨架拓扑和集体振动等多层因素约束，因此结构与电导率之间通常不存在简单的一一映射 [1, 2]。高通量结构筛选能够快速缩小候选空间 [3, 4]，但当数据同时包含 NASICON、硫化物和卤化物等差异显著的体系时，描述符分布与电导率分布都会随体系类型整体平移。此时，全样本相关性可能主要反映“材料属于哪一类”，而非某个结构特征在不同体系中均有效的物理作用。

这一问题本质上属于观测数据中的混杂：体系类型既影响描述符，又影响目标变量 [5]。若不显式控制混杂，元素电负性、空间群或阴离子种类等代理变量可能获得很高的相关系数，却无法用于未见体系。本文将研究目标限定为：在当前可用的小样本数据中，寻找经过去混杂、稳定性校准和跨体系验证后仍可解释的局域结构信号，而不是构建一个在训练集上性能最优但物理意义不透明的黑箱模型。

跨体系数据集与结构描述符空间

当前工程从 107 份原始 CIF 文件出发，经过去重、结构可解析性检查、电导率记录匹配和异常条目审查后，保留 84 个进入统计分析的样本。样本覆盖 NASICON、硫化物和卤化物三类主要体系；现有记录中的体系数量为 30、41 和 13。该不平衡分布使简单随机划分容易高估泛化性能，也是后续采用分层和留一体系验证的直接原因。

描述符全部由静态晶体结构直接计算，不依赖本研究未执行的 DFT 或分子动力学。41 个候选特征按物理含义划分为八族（图 2）：A 族描述 Na 配位多面体；B 族描述 Na-Na 位点网络；C 族描述 Na 浓度与位点占据；D' 族描述空位及瓶颈拓扑；E 族描述骨架刚性和多面体共享；F 族描述长程几何；G 族为电子化学代理；H 族为对称性代理。A-F 族与迁移机制的联系较直接，G-H 族则被预先标记为高混杂风险，不因其统计显著而自动赋予因果解释。

在预处理阶段，bottleneck_anisotropy、bvse_barrier_estimate 和 wyckoff_diversity 三列在当前数据版本中全部缺失，因而从统计模型中移除，剩余 38 个有效物理描述符。零散缺失值使用训练

数据内的中位数填补；所有连续变量在训练折内执行 Z-score 标准化，避免单位和数值范围对 Ridge 系数造成不必要影响。为建立经验零分布，额外生成 15 个固定随机种子的标准正态噪声列，但这些噪声列只用于阈值校准，不作为物理候选。

体系类型是结构-电导率关系的主要混杂源

图 3 概括了本研究的统计假设。令 X_j 为第 j 个结构描述符， Y 为室温离子电导率的 $\log_{10}$ 变换， Z 为体系类型和阴离子类别组成的混杂矩阵。体系类别能够同时改变局域几何的典型范围和电导率的总体分布，因此原始相关 ρ_{raw} 不能直接解释为普适的结构效应。

为减少该偏差，分别对每个 X_j 和 Y 使用 Ridge 回归拟合 Z ，并在残差上计算 Spearman 秩相关：

$$X_j^{\text{res}} = X_j - \hat{\mathbb{E}}(X_j | Z), \quad (1)$$

$$Y^{\text{res}} = Y - \hat{\mathbb{E}}(Y | Z), \quad (2)$$

$$\rho_{\text{deconf}, j} = \rho_s(X_j^{\text{res}}, Y^{\text{res}}). \quad (3)$$

Ridge 收缩可在小样本和哑变量共线的情况下稳定估计混杂部分 [6]。这里使用“去混杂相关”而非“因果效应”这一更谨慎的表述：残差化减少了已观测混杂，但不能排除未观测变量、测量误差或样本选择偏差。与严格的双重机器学习相比 [7]，当前实现属于简化的正交化筛选管线，不提供因果置信区间。

为量化原始相关中可由体系解释的比例，定义带数值保护的混杂衰减指数

$$P_j = \text{clip}\left(1 - \frac{\rho_{\text{deconf}, j}^2}{\rho_{\text{raw}, j}^2 + \varepsilon}, 0, 1\right), \quad (4)$$

其中 ε 为小正数；当 $|\rho_{\text{raw}}|$ 接近零时，特征直接归入噪声级，不使用该比值分类。该修正避免原公式在分母为零或去混杂相关强于原始相关时出现未定义值或负值。

去混杂后仅少量信号保持稳定

当前分析记录中，38 个有效物理描述符经过原始相关、去混杂相关和代理风险联合筛选后，6 个进入稳定性评估；其中 3 个被标记为强物理信号、1 个为弱物理信号、2 个为混合信号。该结果说明，高维候选空间中的多数统

从原始晶体结构到跨体系稳健描述符的六阶段分析框架



图 1. 从原始晶体结构到跨体系稳健描述符的分析框架。原始 107 份 CIF 经质量控制后形成 84 个统计样本；随后依次执行描述符构建、去混杂、稳定性筛选、物理约束组合搜索和多策略交叉验证。图中的“六阶段”指质量控制之后的六个分析模块。

局域结构描述符的八个物理族



A-F 族直接对应迁移几何与载流子条件；G-H 族作为高混杂风险代理变量单独审查。

图 2. 八类局域结构描述符及其风险分层。A-F 族对应局域束缚、位点网络、载流子条件、空位拓扑、骨架响应和长程几何；G-H 族更可能编码体系类别或全局标签，因此在去混杂阶段接受更严格审查。

体系类型会同时改变描述符分布与电导率分布




图 3. 描述符搜索中的混杂结构。体系类型和阴离子类别 Z 同时影响局域结构描述符 X 与电导率 Y 。本文评估的是移除 Z 可解释变异后， X 与 Y 的剩余单调关联。

计关联不足以在控制体系后保持。与直接按全样本相关排序相比，这种压缩显著降低了后续组合搜索的自由度。

稳定性评估采用“Ridge 子采样频率”而非单次 LASSO。每次从样本中无放回抽取 50%，拟合 Ridge 模型，并将系数绝对值超过当次系数中位数的特征记为一次入选；共重复 100 次。真实描述符必须同时满足入选频率高于 0.60，且超过 15 个噪声列入选频率的第 95 百分位数。该做法借鉴稳定性选择以重采样评估特征选择可靠性的思想 [8]，但本文使用的是连续的经验稳定分数，不宣称具备原始稳定性选择理论中的有限样本错误率保证。

该结果还揭示一个重要方法学边界：族内高度相关的描述符不应被机械地视为多个独立发现。例如，最大 Na-

X 键长、平均键长和多面体体积往往共同响应同一局域尺度。为避免同一物理维度在组合搜索中被重复计数，每个物理族原则上只保留一个去混杂相关绝对值最高且稳定性达标的代表。

物理约束组合提升解释力而非无界拟合

离子电导率同时受迁移离子的局域束缚、可达位点和连续路径控制，单一描述符难以覆盖完整机制。因此，组合搜索仅在不同物理族之间进行，并限制为加法、乘法和满足量纲条件的比值。涉及 G-H 族的组合只在存在明确机制解释时保留，避免对高风险代理变量做无约束代数扩张。

当前版本中，最佳单描述符为 A 族的 `poly_distortion_mean`，去混杂 Spearman 相关约为 0.479；当前综合评分最高的二元候选为 `coordination_number_mean / na_site_count`，综合分约为 0.475。两者数值接近，说明在现有样本规模下，组合描述符尚未形成压倒性的统计优势。更合理的解释是：配位环境与可用 Na 位点数量可能提供互补信息，但其增量价值仍需在独立数据和严格嵌套验证中确认。上述数值来自当前工程中的初步分析记录，应以最终冻结的数据表和脚本输出为准。

跨体系验证改变候选描述符的排序

随机 K 折交叉验证容易把同一体系中的近邻样本同时放入训练集和测试集，从而高估“跨体系可迁移性”。本文并行使用三种验证策略（图 4）：阴离子分层 3 折验证检查常规泛化；留一体系验证依次把 NASICON、硫

三种正交验证策略分别检验分布平衡、体系外推和划分稳定性




图 4. 三种正交交叉验证策略。a, 阴离子分层 3 折验证维持主要阴离子类别的比例。b, 留一体系统验证直接评估未见材料体系。c, 10 次分层 80%/20% 子采样估计结果对随机划分的敏感性。

化物或卤化物整体作为未见测试域；重复分层子采样以 10 次 80%/20% 划分估计小样本波动。三种策略的测试集 Spearman 相关绝对值取简单平均形成综合分，同时单独检查相关方向是否一致。

现有记录显示，部分在全样本上相关较高的 SoftBV 或体系代理型基线在留一体系统验证中出现强度崩溃或方向不一致。这一现象支持本文的核心判断：对多体系材料数据，是否能在未见体系保持方向和排序，比单一全样本相关系数更重要。由于卤化物样本仅有 13 个，留出该体系时的方差仍然较大；因此 LOSO 结果应与重复子采样和物理机制解释共同使用，而不能单独作为最终证据。

讨论

本研究的贡献不是提出一个新的高精度预测器，而是把混杂识别、稳定性校准、物理约束和跨体系验证组合为一条可审计的材料描述符筛选链。该链条适合当前这类样本量有限、体系差异大、结构来源异质的材料数据：它明确区分原始相关、去混杂相关和跨体系外推，并要求每个候选都能追溯到具体的结构计算和验证输出。

结果提示，Na 配位多面体的畸变和配位尺度仍是重要的候选信息，但它们不能脱离可用位点数量、Na-Na 连通和空位条件单独解释。另一方面，空间群、电负性或阴离子标签等变量即使具有较高预测力，也更适合作为分层变量或混杂控制项，而不是直接宣称为迁移机制。

当前框架仍有四项限制。第一，84 个样本不足以稳定识别弱效应和高阶交互，尤其是卤化物子集较小。第二，静态 CIF 无法描述温度诱导相变、动态无序、晶界和电极界面。第三，室温电导率来自不同文献与测试条件，残余的密度、频率范围和样品制备差异可能构成未观测混杂。第四，Ridge 残差化只能处理所指定的混杂变量，不能把相关分析提升为严格因果推断。

下一步应以冻结的数据字典和结构版本为基础，执行嵌套交叉验证、标签置换检验和体系内敏感性分析；随后选择少量跨策略稳定的候选材料开展 NEB、AIMD 或实验阻抗复核。本文没有运行 DFT、NEB 或分子动力学，因此所有机理结论均限于结构统计层面的候选解释。

方法

数据纳入和质量控制

原始输入为 107 份钠离子固态电解质 CIF。质量控制依次检查文件可解析性、化学组成、周期结构、重复结构、Na 元素存在性以及室温离子电导率记录的可追踪匹配。只有同时具备可用晶体结构和明确目标值的条目进

入统计分析。不同组成、晶相、热处理或独立测试条件应作为独立记录保留；若多个电导率值对应同一结构但实验条件不可区分，则不得以简单平均替代原始记录。当前质量控制后样本数为 84。

目标变量为室温离子电导率 σ 的 $\log_{10}(\sigma/\text{S cm}^{-1})$ 。对非室温数据，不通过 Arrhenius 外推生成目标值，除非原始文献明确报告拟合参数和适用温区。该原则避免把不同相区或不同导电机制混入同一标签。

描述符计算与物理族划分

描述符从 CIF 静态结构直接获得，包括 Na 配位数、Na-X 键长统计、多面体体积与畸变、最近 Na-Na 距离、Na 网络维度、单位体积 Na 数量、位点占据、空位比例、Voronoi 空隙、通道瓶颈、骨架多面体共享、自由体积分数和对称性统计等。完整候选集合包含 41 项，按图 2 所示归入八个物理族。软件依赖型输出必须同时记录软件版本、探针半径、截断半径和失败状态；计算失败使用缺失值，而不是 999 等数值占位符。

在当前数据中，三列全缺失特征被整体剔除。其余缺失值仅在每个训练折内以中位数填补，标准化参数也自由训练折估计，再应用于测试折，以防止信息泄漏。

混杂残差化

混杂矩阵 Z 包含体系类型和主要阴离子类别的 one-hot 编码。对目标 Y 和每个描述符 X_j 分别拟合 Ridge 回归

$$\hat{\beta} = \arg \min_{\beta} \|v - Z\beta\|_2^2 + \alpha \|\beta\|_2^2, \quad (5)$$

其中 v 依次取 Y 或 X_j ，当前默认 $\alpha = 1$ 。残差化后计算 Spearman 秩相关和双侧置换检验。所有筛选阈值和随机种子在分析前写入配置文件，避免根据结果反复调参。

描述符初筛采用五类标签：强物理信号、弱物理信号、混合信号、体系代理和噪声级。标签同时依据 $|\rho_{\text{deconf}}|$ 、混杂衰减指数 P_j 和 $|\rho_{\text{raw}}|$ ，但阈值只用于候选压缩，不等于统计显著性声明。多重比较的正式推断应另外报告假发现率控制结果。

Ridge 子采样稳定性评分

对初筛保留的真实描述符与 15 个噪声列执行 100 次 50% 无放回子采样。每次使用相同的预处理管线拟合 Ridge 模型；若某个特征的系数绝对值高于本次所有候选系数绝对值的中位数，则记为入选。稳定性分数为 100 次入选比例。候选必须满足稳定性分数大于 0.60，并超过噪声列稳定性分数的第 95 百分位数。该经验阈值用于排除容易由随机划分产生的高频假信号。

族代表和组合描述符

对每个物理族，从稳定性合格特征中选择 $|\rho_{\text{deconf}}|$ 最大者作为主代表。组合搜索仅允许不同物理族之间的加法、乘法和受量纲约束的比值；分母绝对值小于预设阈值的样本被标记为不可计算，不用任意大数替代。候选组合在训练折内生成和筛选，禁止先使用全数据选出最佳组合后再进行交叉验证。

多策略验证与综合评分

阴离子分层 3 折验证在各折中尽量保持 O、S 和卤素类别比例；留一体系统验证依次将一个材料体系全部留作测试集；重复分层子采样执行 10 次 80%/20% 划分。每次评估报告测试集 Spearman 相关、均方误差、相关方向和有效样本数。综合评分定义为

$$S = \frac{|\rho_{\text{anion}}| + |\rho_{\text{LOSO}}| + |\rho_{\text{subsample}}|}{3}. \quad (6)$$

若三种策略的相关方向不一致，则无论 S 多高均标记为“方向不稳健”。在最终实现中，组合搜索、填补、标准化和模型超参数选择均应嵌套在训练折内部。

复现要求

每次运行至少保存以下文件：结构清单及哈希、目标值来源表、描述符矩阵、缺失值报告、预处理参数、随机种子、各阶段候选清单、每折训练/测试索引、预测值和最终排序。环境文件应固定 Python、pymatgen、ASE、scikit-learn、NumPy 和 SciPy 版本；涉及 Zeo++ 或 SoftBV 的描述符需额外记录可执行文件版本和命令行参数。

数据与代码可用性

本稿基于当前仓库中的 LaTeX 工程和既有分析记录整理。用于最终论文结论的数据表、结构哈希、描述符计算脚本和交叉验证输出应在结果冻结后提供稳定版本号或公开存档地址。当前 PDF 不包含未运行的 DFT、NEB 或分子动力学结果。

致谢

致谢信息待补充。

作者贡献

作者贡献信息待补充。

利益冲突

作者声明信息待补充。

补充信息

补充材料清单、扩展数据图和完整描述符字典待最终数据冻结后生成。

参考文献

- [1] Michel Armand and Jean-Marie Tarascon. “Building better batteries”. In: *Nature* 451 (2008), pp. 652–657.
- [2] John Christopher Bachman, Soksei Muy, Alexis Grimaud, et al. “Inorganic Solid-State Electrolytes for Lithium Batteries: Mechanisms and Properties Governing Ion Conduction”. In: *Chemical Reviews* 116.1 (2016), pp. 140–162.
- [3] Stefan Adams and R. Prasada Rao. “High throughput ionic conductivity screening of NASICON-type structures”. In: *physica status solidi (a)* 203.6 (2006), pp. 1226–1234.
- [4] Austin D. Sendek, Qian Yang, Ekin D. Cubuk, et al. “Holistic computational structure screening of more than 12,000 candidates for solid lithium-ion conductor materials”. In: *Energy & Environmental Science* 10 (2017), pp. 306–320.
- [5] Judea Pearl. *Causality: Models, Reasoning, and Inference*. 2nd ed. Cambridge: Cambridge University Press, 2009.
- [6] Arthur E. Hoerl and Robert W. Kennard. “Ridge Regression: Biased Estimation for Nonorthogonal Problems”. In: *Technometrics* 12.1 (1970), pp. 55–67.
- [7] Victor Chernozhukov, Denis Chetverikov, Mert Demirer, et al. “Double/debiased machine learning for treatment and structural parameters”. In: *The Econometrics Journal* 21.1 (2018), pp. C1–C68.
- [8] Nicolai Meinshausen and Peter Bühlmann. “Stability selection”. In: *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 72.4 (2010), pp. 417–473.